HACKATHON GIVAUDAN 2026 / LIVRAISON DU JEUDI 12 NOVEMBRE

Brique Data & ML
Dossier de validation V2

Projet Sillage • Équipe G22 / Auralis • Référentiel 30 cas • Version expérimentale

30	29 / 30	0,967
cas alimentaires	classifications correctes RF	F1 macro, validation rétrospective

Objet du rendu

Ce document synthétise les preuves Data & ML déposées dans la branche commune develop pour la revue du jeudi : préparation des données, critères de validation définis avec Product et publication du modèle V2 pour Tech. Il complète les fichiers de code et les rapports déjà accessibles dans le dépôt ; il ne se substitue pas aux livrables Product remis séparément.

Les trois attendus du jeudi

Exigence de la séance	Livraison et preuve accessible
Données exploitables	Jeux nettoyés et préparés en CSV, rapports qualité, 12 784 observations / 136 séries pays / 30 aliments pour M3–M4 ; 1 786 observations Google Trends géographiques dans le lot P0 M1.
Critères de validation	Cadrage effectué avec Product selon la confirmation de l'équipe ; protocole documenté, métriques, comparaison de trois modèles et prédictions par cas. Les labels historiques restent à auditer indépendamment.
Modèle V2 publié	Random Forest retenu ; fichier model_v2.joblib, code d'inférence, tests locaux et API FastAPI consultables par Tech dans develop. L'intégration au front et au backend collectif n'est pas démontrée.

Source principale : LIVRABLES_V2.md | README Data & ML

02 / VALIDATION DU MODÈLE

Critères, protocole et résultats

Validation technique expérimentale de la classification « buzz » / « tendance durable ».

Critères testables retenus

Critère	Méthode de vérification
Conformité des données	Sujets alimentaires uniquement, séries mensuelles datées, pays identifiables, indices Google Trends de 0 à 100 ; WORLD n'est pas assimilé à un pays.
Non-contamination du test	Leave-One-Topic-Out : chaque aliment est entièrement retiré du jeu d'entraînement de son fold ; pas de mélange de mois/pays d'un même sujet entre train et test.
Qualité de classification	Nombre correct / total, accuracy, précision, rappel, F1 macro et matrice de confusion sur les 30 cas étiquetés.
Comparaison au niveau de base	Comparer Logistic Regression, Random Forest, XGBoost et baseline « toujours buzz » à périmètre identique.
Réponse utile pour le prototype	API renvoyant identité du modèle, métriques, exemples de cas et classification calculée à partir d'observations transmises ; mention explicite du statut expérimental.

Résultat du benchmark - 30 sujets (15 buzz / 15 tendances)

Méthode	Corrects	Accuracy	F1 macro
Baseline : toujours buzz	15 / 30	0,500	0,333
Logistic Regression	28 / 30	0,933	0,933
Random Forest - retenu	29 / 30	0,967	0,967
XGBoost	27 / 30	0,900	0,900

Random Forest : 15 vrais négatifs, 0 faux positif, 1 faux négatif, 14 vrais positifs. L'unique erreur du référentiel concerne dubai_chocolate. En excluant la pistache provisoire : 28/29 corrects et F1 macro ≈ 0,965.

Interprétation : l'évaluation utilise des trajectoires historiques complètes et les étiquettes fournies par l'équipe. Elle ne prouve ni une prédiction avant le pic, ni la généralisation à de nouveaux ingrédients. La sélection du meilleur modèle sur les mêmes 30 cas peut créer un biais de sélection.

Preuves : Métriques JSON | Prédictions par cas | Protocole et tests

Artefacts, API et reproductibilité

Accès au code et au modèle directement depuis le repository collectif.

Fichiers à reprendre par Tech

Ressource	Chemin GitHub dans sillage-ml/
Modèle sérialisé	m2_classifier_v2/artifacts/comparison_v2/model_v2.joblib
Métriques et audit	m2_classifier_v2/artifacts/comparison_v2/metrics_v2.json et audit_30_references.csv
Données préparées	m3_forecasting/data/processed/m3_30_foods_geo_2019_2026.csv
Code API et tests	m2_classifier_v2/sillage_v2/api.py ; m2_classifier_v2/tests/
Guide collectif	LIVRABLES_V2.md ; m2_classifier_v2/README_COMPARAISON_V2.md

Lancer localement le modèle V2

Depuis le dossier sillage-ml/m2_classifier_v2 dans un environnement Python adapté :

```
python -m pip install -r requirements-comparison.txt
python -m pytest -q
export SILLAGE_V2_ARTIFACT_DIR="artifacts/comparison_v2"
uvicorn sillage_v2.api:app --port 8004
```

Documentation interactive locale : http://127.0.0.1:8004/docs. Contrôles documentés : GET /v2/model, GET /v2/metrics, GET /v2/cases et POST /v2/predict. La sortie de /predict est calculée par le modèle enregistré et n’est pas un verdict codé en dur. Les tests sont rapportés comme réussis localement ; aucun service de production n’est déclaré.

Résultats complémentaires et limites de périmètre

M1 : 56 alertes candidates sur 1 786 observations Google Trends P0, non validées comme événements réels. M3 : prévisions à trois mois sur 136 séries ; méthode Last Value retenue sur les folds de sélection (MAE 7,6517), MAE sur holdout 10,9743 ; la naïve saisonnière fait 10,1593 sur ce holdout. M4 : 104 séries avec signal et 22 aliments comparables entre au moins deux pays ; chronologie relative, pas preuve de diffusion causale. M5 : RAG documentaire fictif, non intégré au métier.

Limites transverses : données Google Trends normalisées relativement (0–100), risques de normalisation rétrospective, labels métier non audités indépendamment, pistache provisoire ; aucune mesure de performance prospective du pipeline complet. Les droits de republication des sources et des tables dérivées doivent être vérifiés par l’équipe.

Accès : Dossier des cinq livrables | Modèle V2 | API Python